

Video Coding for Machine Vision Applications

Αλίκη Ζηλίδου¹, Μαρία-Ειρήνη Στρατάκη², Παναγιώτης Λιάμπας³

¹A.M. 2122198, email: azilidou@uth.gr

²A.M. 2122227, email: mastrataki@uth.gr

³A.M. 2122144, email: pliampas@uth.gr

Abstract

Η παρούσα εργασία διερευνά τις επιδόσεις των μεθόδων Μαθημένης Συμπίεσης Εικόνας (LIC) σε ένα πλαίσιο σχετικό με την Κωδικοποίηση Βίντεο για Μηχανική Όραση (VCM). Αξιολογήθηκαν τρία μοντέλα (bmshj2018-factorized, mbt2018, cheng2020-attn) ως προς τη σχέση Ρυθμού-Παραμόρφωσης (R-D) και την υπολογιστική πολυπλοκότητα. Τα αποτελέσματα έδειξαν ότι, παρά την ανώτερη ποιότητα των `cheng2020-attn` και `mbt2018`, αυτά είναι έως και 20 φορές πιο αργά από το `bmshj2018`, αναδεικνύοντας τον κρίσιμο συμβιβασμό μεταξύ της επίδοσης R-D και του χρόνου εκτέλεσης σε εφαρμογές πραγματικού χρόνου. Η μελέτη αποκοπής επιβεβαίωσε, επίσης, τη βελτίωση της ποιότητας με την προσθήκη του μηχανισμού Hyperprior.

1 Introduction

Η ραγδαία αύξηση της ψηφιακής πληροφορίας βίντεο καθιστά τη συμπίεση απαραίτητη. Τα κλασικά πρότυπα, όπως το VVC (H.266), βασίζονται στο υβριδικό σχήμα κωδικοποίησης με βάση τα μπλοκ. Ωστόσο, ο τομέας Video Coding for Machines (VCM) σηματοδοτεί τη μετατόπιση του στόχου της συμπίεσης από την οπτική ποιότητα (Rate-Distortion, R-D) στην ακρίβεια των εργασιών μηχανικής όρασης (Rate-Accuracy, R-A). Αυτή η μετατόπιση οδήγησε στην ανάπτυξη της Μαθημένης Συμπίεσης (Learned Compression), η οποία χρησιμοποιεί αρχιτεκτονικές Αυτοκωδικοποιητών για βελτιστοποίηση R-D από άκρο σε άκρο.

Στην παρούσα εργασία, αξιολογούνται τρία βασικά μοντέλα Μαθημένης Συμπίεσης Εικόνας (bmshj2018-factorized, mbt2018, cheng2020-attn) ως προς την επίδοση Ρυθμού-Παραμόρφωσης (R-D) και την υπολογιστική τους πολυπλοκότητα.

2 Background

2.1 Classical compression

Η κλασική συμπίεση βίντεο, βασίζεται στο υβριδικό σχήμα κωδικοποίησης βίντεο που λειτουργεί με βάση τα μπλοκ. Αυτό το σχήμα χωρίζεται σε μία σειρά από διακριτά αλλά και αλληλένδετα στάδια, με σκοπό την μείωση της πλεονασματικής πληροφορίας και την επίτευξη υψηλότερης απόδοσης κωδικοποίησης (μείωση ρυθμού bit) για την ίδια ποιότητα βίντεο. Παρακάτω παρουσιάζονται τα κύρια στάδια του κλασικού βρόχου συμπίεσης.

2.1.1 Prediction

Το στάδιο της πρόβλεψης στοχεύει στην εκμετάλλευση της χωρικής (ενδο-εικόνα) και χρονικής (δια-εικόνα) πλεονασματικότητας. Ένα μπλοκ εικόνας προβλέπεται χρησιμοποιώντας είτε με Intra-Picture Prediction όπου η πρόβλεψη γίνεται από ήδη ανακατασκευασμένα δείγματα (pixels) τα οποία βρίσκονται εντός της ίδιας εικόνας, είτε με Inter-Picture Prediction όπου η πρόβλεψη γίνεται με αντιστάθμιση κίνησης (motion compensation) από ήδη αποκωδικοποιημένες εικόνες αναφοράς σε διαφορετικά χρονικά σημεία. Αυτό περιλαμβάνει την εύρεση και κωδικοποίηση διανυσμάτων κίνησης (motion vectors – MVs) και την εκτέλεση αντιστάθμισης κίνησης. Η διαφορά μεταξύ του αρχικού μπλοκ και του προβλεπόμενου σήματος ονομάζεται : σήμα σφάλματος πρόβλεψης (prediction residual)

2.1.2 Transforms

Το σήμα σφάλματος πρόβλεψης μετασχηματίζεται για να επιτευχθεί συμπίκνωση ενέργειας (energy compaction). Η ενέργεια συγκεντρώνεται σε λίγους συντελεστές χαμηλής συχνότητας, ενώ πολλοί συντελεστές υψηλής συχνότητας γίνονται μικροί ή μηδενικοί γεγονός που διευκολύνει το επόμενο στάδιο της κβάντισης. Χρησιμοποιούνται μετασχηματισμοί ακεραίων αριθμών (integer transforms).

2.1.3 Quantization

Οι συντελεστές του μετασχηματισμένου σήματος σφάλματος κβαντίζονται δηλαδή στρογγυλοποιούνται σε διακριτά επίπεδα. Αυτή η διαδικασία είναι συνήθως η κύρια πηγή απώλειας πληροφορίας στη συμπίεση βίντεο. Η κβάντιση βαθμωτού ομοιόμορφου ανακατασκευαστή (Scalar Uniform Reconstruction Quantizer – URQ) είναι συμβατική μέθοδος. Το βήμα κβάντισης (Δ) και η παράμετρος κβάντισης (Quantization Parameter - QP) ελέγχουν πόσο επιθετική είναι η κβάντιση και κατ' επέκταση την ποιότητα και τον ρυθμό bit.

2.1.4 Entropy Coding

Οι κβαντισμένοι συντελεστές μετασχηματισμού (transform coefficient levels) καθώς και οι παράμετροι διαμέρισης και πρόβλεψης κωδικοποιούνται με εντροπία

(entropy coded). Αυτό το στάδιο είναι χωρίς απώλειες και στοχεύει στην περαιτέρω μείωση του ρυθμού bit.

2.2 Learned Image Compression

Η Learned Image Compression (LIC) χρησιμοποιεί βαθιά νευρωνικά δίκτυα για να ξεπεράσει τα κλασικά π'ότυπα εστιάζοντας στη βελτιστοποίηση της σχέσης Ρυθμού-Παραμόρφωσης (Rate-Distortion, R-D) μέσω εκπαίδευσης από άκρο σε άκρο (end-to-end).

2.2.1 Autoencoders

Η αρχιτεκτονική του Αυτοκωδικοποιητή Συμπίεσης (Compressive Autoencoder – CAE) αποτελεί τη βάση των περισσότερων μεθόδων LIC. Ένας CAE αποτελείται από δύο κύρια μέρη τον κωδικοποιητή και τον αποκωδικοποιητή. Ο Κωδικοποιητής (Encoder) είναι ένα νευρωνικό δίκτυο που μετατρέπει την αρχική εικόνα σε μία λανθάνουσα αναπαράσταση χαμηλότερης διάστασης. Ο Αποκωδικοποιητής (Decoder) είναι ένα νευρωνικό δίκτυο που ανακατασκευάζει την εικόνα από την κβαντισμένη λανθάνουσα αναπαράσταση.

Η εκπαίδευση του CAE βελτιστοποιείται για να ελαχιστοποιήσει το άθροισμα του ρυθμού bit της λανθάνουσας αναπαράστασης και της παραμόρφωσης μεταξύ της αρχικής και της ανακατασκευασμένης εικόνας.

2.2.2 Entropy Models

Τα μοντέλα εντροπίας είναι σημαντικά για την αποτελεσματική κωδικοποίηση εντροπίας της λανθάνουσας αναπαράστασης. Σκοπός τους είναι να εκτιμήσουν την κατανομή πιθανότητας της λανθάνουσας αναπαράστασης με την μέγιστη δυνατή ακρίβεια.

2.2.3 CompressAI families

Το CompressAI είναι μια ανοιχτή βιβλιοθήκη PyTorch που λειτουργεί ως πλατφόρμα ανάπτυξης έρευνας και αξιολόγησης κωδικοποιητών συμπίεσης από άκρο σε άκρο. Παρέχει προ-εκπαιδευμένα μοντέλα τα οποία βασίζονται σε δημοσιευμένες μεθόδους LIC, επιτρέποντας τους ερευνητές να συγκρίνουν εύκολα τις νέες προσεγγίσεις με την τρέχουσα τεχνολογία αιχμής. Μπορεί να απλοποιήσει την έρευνα προσφέροντας τυποποιημένα εργαλεία για την μέτρηση PSNR και MS-SSIM έναντι του ρυθμού bit (R-D) χρησιμοποιώντας γνωστά σύνολα δοκιμών όπως το Kodak.

2.3 VVC and uvg266 as the baseline for video

Το VVC (γνωστό και ως H.266) είναι το πιο πρόσφατο διεθνές πρότυπο κωδικοποίησης βίντεο και αποτελεί το νέο κλασικό σημείο αναφοράς (baseline) στην κωδικοποίηση βίντεο. Σχεδιάστηκε για να προσφέρει περίπου 50%

μεγαλύτερη αποδοτικότητα συμπίεσης (μείωση ρυθμού bit για την ίδια ποιότητα) σε σχέση με τον προκάτοχο του, το HEVC (H.265). Ενώ διατηρεί το υβριδικό σχήμα κωδικοποίησης βίντεο με βάση τα μπλοκ, εισάγει εκατοντάδες νέα και βελτιωμένα εργαλεία κωδικοποίησης. Χρησιμοποιείται ως η βασική γραμμή σύγκρισης για την αξιολόγηση της απόδοσης όλων των νέων μαθημένων κωδικοποιητών βίντεο (Learned Video Compression – LVC).


Το `uv266` είναι μία πρακτική και βελτιστοποιημένη υλοποίηση ενός ενδο-κωδικοποιητή (Intra Encoder) VVC. Δημιουργήθηκε ως αναβάθμιση του κωδικοποιητή HEVC Kvaazaar. Παρέχει μια αποδοτική, πραγματική βάση για την δοκιμή και την σύγκριση. Η ύπαρξη ενός πρακτικού κωδικοποιητή VVC είναι απαραίτητη για την εμπορική υιοθέτηση και την ερευνητική σύγκριση.

2.4 VCM/FCM accuracy vs rate, usage scenarios

Οι τομείς Video coding for machines (VCM) και Feature coding for machines (FCM) αντιπροσωπεύουν μια σημαντική αλλαγή στην συμπίεση δηλαδή αυτή δεν βελτιστοποιείται πλέον για το ανθρώπινο μάτι αλλά για την καλύτερη επίδοση σε εργασίες μηχανικής όρασης (computer vision). Η προσέγγιση Ρυθμού-Ακρίβειας (Rate Accuracy – R-A) σηματοδοτεί τη μετατόπιση του στόχου της συμπίεσης Video/Feature Coding for Machines από την οπτική ποιότητα (Rate-Distortion - R-D) προς την ακρίβεια εργασίας (Task Accuracy – A). Αντί να μεγιστοποιείται η παραδοσιακή οπτική πιστότητα (π.χ. οι μετρικές PSNR/SSIM), ο αρχικός στόχος είναι η επίτευξη της μέγιστης δυνατής ακρίβειας σε εργασίες μηχανικής όρασης για έναν δεδομένο ρυθμό bit.

Η αξιολόγηση των μεθόδων VCM/FCM γίνεται μέσω πλατφορμών όπως το CompressAI-Vision το οποίο υιοθετήθηκε από την MPEG για την ανάπτυξη του προτύπου FCM. Υπάρχουν δύο κύρια inference scenarios. Το πρώτο είναι το Remote Inferencing που έχει ως διαδικασία ότι ολόκληρη η εικόνα ή το βίντεο συμπιέζεται με έναν συμβατικό κωδικοποιητή, μεταδίδεται και στην συνέχεια το Νευρωνικό Δίκτυο Όρασης (Vision NN) τρέχει στον απομακρυσμένο δέκτη. Στόχος του είναι ότι η συμπίεση πρέπει να διατηρεί της οπτική πληροφορία αρκετά καλά ώστε το Vision NN να διατηρήσει την αρχική του ακρίβεια. Το δεύτερο είναι το Split Inferencing / Κωδικοποίηση Χαρακτηριστικών FCM που έχει ως διαδικασία το νευρωνικό δίκτυο όρασης να διαιρείται. Ένα τμήμα του τρέχει στον κωδικοποιητή (πηγή) παράγοντας ενδιάμεσα χαρακτηριστικά. Αυτά τα χαρακτηριστικά συμπιέζονται (εδώ εφαρμόζεται η FCM) και μεταδίδονται. Το υπόλοιπο τμήμα του δικτύου τρέχει στον αποκωδικοποιητή (δέκτης) για την τελική εργασία. Στόχος του είναι η συμπίεση να μην εφαρμόζεται στην εικόνα αλλά απευθείας στα χαρακτηριστικά του νευρωνικού δικτύου επιτρέποντας δραστηκή μείωση του ρυθμού bit με ελάχιστη απώλεια στην ακρίβεια της τελικής εργασίας.

3 Guidelines regarding the project





Τα frames του βίντεο βρίσκονται στο φάκελο `video_data / frames_original` (BONUS-1).

Sequence Name	Original Resolution	Processed Resolution	FPS	Total Frames Used
FlowerFocus	\$3840 \times 2160\$ (4K)	\$960 \times 540\$	50	100

4 Methodology & Protocol

- Η επιλογή του "Quality ladder" (βαθμίδας ποιότητας) γίνεται στο αρχείο `run_image.py` (και στο `run_ablation.py`) και καθορίζει τα επίπεδα συμπίεσης στα οποία θα αξιολογηθούν τα μοντέλα. Στο αρχείο `run_image.py`, η μεταβλητή `QUALITIES` ορίζεται ρητά ως μια λίστα πέντε (5) ακέραιων τιμών, ικανοποιώντας την απαίτηση για 5-7 σημεία. Αυτά τα επίπεδα ποιότητας [2, 3, 4, 5, 6] αντιστοιχούν στις προ-εκπαιδευμένες ρυθμίσεις του `CompressAI` για τα μοντέλα συμπίεσης, όπου το 2 συνήθως δίνει την υψηλότερη συμπίεση (χαμηλό bpp) και το 6 δίνει τη χαμηλότερη συμπίεση (υψηλό bpp). Η κάθε τιμή του `q` χρησιμοποιείται για τη φόρτωση της αντίστοιχης έκδοσης του μοντέλου με την εντολή: `model = model_func(quality=q, pretrained=True).eval().to(device)`.
- Ο πειραματικός σχεδιασμός εξασφαλίζει τη δικαιοσύνη και την αναπαραγωγιμότητα μέσω τριών βασικών κανόνων. Όλα τα πειράματα, τόσο το βασικό όσο και το `ablation`, χρησιμοποιούν το ίδιο σύνολο δεδομένων που βρίσκεται στον κατάλογο `./data_preprocessed`. Αυτό το σύνολο δεδομένων έχει υποστεί πανομοιότυπη προεπεξεργασία από το script `preprocess.py`, όπου όλες οι εικόνες μετατράπηκαν σε ανάλυση 512x512. Τέλος, εφαρμόζεται κλείδωμα έκδοσης (`version locking`),

καθώς φορτώνονται συγκεκριμένα προ-εκπαιδευμένα (pretrained) μοντέλα από τη βιβλιοθήκη CompressAI για κάθε επίπεδο ποιότητας, διασφαλίζοντας έτσι ότι οι αλγόριθμοι που συγκρίνονται είναι οι ίδιοι σε κάθε εκτέλεση.



- Η αξιολόγηση των συμπεστών εικόνας βασίζεται σε τρεις κύριες μετρικές. Η επίδοση του ρυθμού (rate) μετράται με τα bits per pixel (bpp), τα οποία υπολογίζονται από το συνολικό μέγεθος του bitstream του κωδικοποιητή σε σχέση με τον αριθμό των pixels της εικόνας. Για τη μέτρηση της παραμόρφωσης (distortion), χρησιμοποιούνται δύο μετρικές: το PSNR (Peak Signal-to-Noise Ratio), το οποίο αποτελεί αντικειμενική μέτρηση ποιότητας βασισμένη στο σφάλμα MSE, και το MS-SSIM (Multi-Scale Structural Similarity), το οποίο παρέχει μια μέτρηση πιο κοντά στην ανθρώπινη οπτική αντίληψη.
- Τα αποτελέσματα των πειραμάτων αποθηκεύονται σε αρχεία τύπου CSV (Comma Separated Values) στον κατάλογο `./results`. Το βασικό πείραμα αποθηκεύεται στο `image_rd_results.csv`, ενώ τα αποτελέσματα της μελέτης αποκοπής αποθηκεύονται στο `ablation_results.csv`. Τα αρχεία περιλαμβάνουν τα απαιτούμενα πεδία (headings) για την πλήρη καταγραφή των δεδομένων. Πιο συγκεκριμένα, αυτά είναι τα αναγνωριστικά `img`, `model`, και `level`, ακολουθούμενα από τις μετρικές `bpp`, `psnr`, `ms_ssim`, και τέλος τις μετρικές χρόνου `enc_time`, `dec_time`, καθώς και το πεδίο `mem`.
- Η μελέτη αποκοπής (Ablation Study) έχει σχεδιαστεί για να απομονώσει και να αξιολογήσει τη συμβολή ενός συγκεκριμένου αρχιτεκτονικού στοιχείου στην επίδοση του συμπεστή. Η αλλαγή αφορά τη σύγκριση δύο παραλλαγών του ίδιου βασικού μοντέλου: το `bmshj2018-factorized` (βασικό πείραμα) συγκρίνεται με το `bmshj2018-hyperprior` (ablation πείραμα). Η κεντρική αλλαγή είναι η εισαγωγή του υπερ-δικτύου (hyperprior), το οποίο μοντελοποιεί τις εξαρτήσεις των κωδικοποιημένων latents. Αυτή η σύγκριση αποκαλύπτει με ακρίβεια πόσο βελτιώνει την καμπύλη Ρυθμού-Παραμόρφωσης (PSNR/MS-SSIM έναντι bpp) η προσθήκη του μηχανισμού Hyperprior, σε σχέση με την πιο απλή factorized εκδοχή.



5 Implementation

- OS (Λειτουργικό): Windows 11 (64bit)
PyTorch Version: 2.9.1+cpu

CompressAI Ver.: 1.2.8
Execution Device: CPU
Python: 3.10.11
FFmpeg: 7.1 (Essentials Build from Gyan.dev)
uv266: v0.2.2


- preprocess.py: Αυτό το αρχείο είναι υπεύθυνο για την προετοιμασία των δεδομένων. Παίρνει τις εικόνες από τον κατάλογο ../data και τις μετασχηματίζει (Resize και CenterCrop) σε ανάλυση 512×512 .
run_image.py: Το κύριο script αξιολόγησης. Εκτελεί τη συμπίεση και αποσυμπίεση των τριών βασικών μοντέλων (bmshj2018-factorized, mbt2018, cheng2020-attn) σε 5 επίπεδα ποιότητας [2, 3, 4, 5, 6]. Υπολογίζει τις μετρικές bpp, PSNR, MS-SSIM και αποθηκεύει τα αποτελέσματα στο image_rd_results.csv.
run_ablation.py: Το script για τη μελέτη αποκοπής. Λειτουργεί πανομοιότυπα με το run_image.py, αλλά αξιολογεί το μοντέλο bmshj2018-hyperprior στα ίδια επίπεδα ποιότητας. Τα αποτελέσματα αποθηκεύονται στο ablation_results.csv.
create_plots.py / create_plots_ablation.py: Αυτά τα scripts είναι υπεύθυνα για τη δημιουργία των διαγραμμάτων Rate-Distortion (bpp vs. PSNR και bpp vs. MS-SSIM) από τα αρχεία CSV. Το create_plots_ablation.py ενώνει τα αποτελέσματα των βασικών μοντέλων και του ablation μοντέλου για την συγκριτική απεικόνιση.
run.py: Το κεντρικό script εκτέλεσης (orchestration). Εκτελεί όλα τα επιμέρους scripts με τη σωστή σειρά: preprocess.py $\rightarrow$ run_image.py $\rightarrow$ run_ablation.py $\rightarrow$ create_plots.py $\rightarrow$ create_plots_ablation.py.






6 Experimental Setup

- Τύπος Pipeline (Ροής): Remote (Συμπίεση Εικόνας ακολουθούμενη από Ανάλυση/Υπολογισμό Μετρικών). Χρησιμοποιήσαμε end-to-end μοντέλα συμπίεσης εικόνας (bmshj2018, mbt2018) τα οποία εφαρμόστηκαν σε κάθε καρέ ξεχωριστά (frame-by-frame).
- Σύνολο Δοκιμής (Test Set): Η ακολουθία *FlowerFocus* από το σύνολο δεδομένων UVG (100 καρέ), με κλιμάκωση (downscaling) σε ανάλυση 960×540 .
- Ανιχνευτής & Μετρικές: Λόγω της απουσίας σχολιασμών αναφοράς (ground-truth annotations) για την ανίχνευση αντικειμένων στο συγκεκριμένο raw βίντεο UVG, δεν χρησιμοποιήσαμε κάποιον συγκεκριμένο ανιχνευτή αντικειμένων (π.χ. Faster R-CNN). Αντ' αυτού, αξιολογήσαμε την Ποιότητα Σήματος (Signal Fidelity - PSNR) σε πολλαπλά επίπεδα ποιότητας (Ποιότητες 3, 5 και 6), ώστε να καταδείξουμε την απόδοση Ρυθμού-Παραμόρφωσης (Rate-Distortion) των μοντέλων σε δεδομένα βίντεο.




Υπάρχει ένα σαφές trade-off όπου τα μοντέλα υψηλής ποιότητας (mbt2018, cheng2020-attn) απαιτούν έως και 20 φορές περισσότερο χρόνο για την κωδικοποίηση σε σχέση με τα ταχύτερα μοντέλα bmshj2018, ανεξαρτήτως του ρυθμού bpp.




Η διαφορά στην πολυπλοκότητα είναι ακόμη πιο έντονη στην αποκωδικοποίηση, με τα μοντέλα mbt2018 και cheng2020-attn να απαιτούν έως και 14 δευτερόλεπτα, υποδηλώνοντας ότι δεν είναι κατάλληλα για εφαρμογές πραγματικού χρόνου σε σύγκριση με τις εκδόσεις bmshj2018.


7 Results




Τα μοντέλα cheng2020-attn και mbt2018 παρουσιάζουν την καλύτερη αντικειμενική ποιότητα (PSNR) σε σχέση με τα bpp, αφήνοντας το bmshj2018-factorized να υπολείπεται.



Το cheng2020-attn δείχνει σαφή υπεροχή στην αντιληπτική ποιότητα (MS-SSIM) έναντι του mbt2018 και του bmshj2018-factorized.




Η προσθήκη του μηχανισμού Hyperprior (bmshj2018-hyperprior) βελτιώνει αισθητά την αντικειμενική ποιότητα (PSNR) του βασικού μοντέλου bmshj2018-factorized, αλλά παραμένει κάτω από τα πιο σύνθετα mbt2018 και cheng2020-attn.



Η μελέτη αποκοπής επιβεβαιώνει ότι το Hyperprior προσφέρει επίσης βελτίωση στην αντιληπτική ποιότητα (MS-SSIM) σε σχέση με το Factorized μοντέλο, με τα mbt2018 και cheng2020-attn να διατηρούν την κορυφή.

Rate-Distortion performance (PSNR vs Bitrate) for video sequence FlowerFocus.



8 Discussion

Η σύγκριση των μοντέλων αποκαλύπτει την ιεραρχία στην επίδοση και την πολυπλοκότητα. Τα μοντέλα cheng2020-attn και mbt2018 είναι πιο αποδοτικά στην ποιότητα, καθώς τοποθετούνται ψηλότερα στις καμπύλες Rate-Distortion (RD) για PSNR και MS-SSIM. Αυτό οφείλεται κυρίως στην υιοθέτηση πιο σύνθετων αρχιτεκτονικών: το cheng2020-attn χρησιμοποιεί μηχανισμούς Attention (προσοχής) για καλύτερη προσαρμογή στην κατανομή των bits, βελτιώνοντας την ποιότητα σε περιοχές με λεπτομερή υφή (texture). Σε αντίθεση, το bmshj2018-factorized υπολείπεται λόγω της απλούστερης factorized κατανομής του, η οποία δεν μοντελοποιεί αποτελεσματικά τις χωρικές εξαρτήσεις, οδηγώντας σε χαμηλότερη ποιότητα για τον ίδιο ρυθμό.

Η μελέτη αποκοπής (Ablation) επιβεβαιώνει την κρίσιμη σημασία της κατανομής των bits (bit-allocation): η προσθήκη του Hyperprior στο μοντέλο bmshj2018 βελτιώνει την επίδοση, τοποθετώντας το hyperprior αρκετά πιο πάνω από το factorized. Αυτό οφείλεται στην ικανότητα του Hyperprior να μοντελοποιεί τις εξαρτήσεις των κωδικοποιημένων χαρακτηριστικών, επιτρέποντας μια πιο έξυπνη και αποτελεσματική κατανομή των bits. Ωστόσο, αυτή η βελτίωση στην ποιότητα έχει ως αρνητικό την πολυπλοκότητα (Decoding/Encoding Time), όπου τα μοντέλα υψηλής επίδοσης (mbt2018, cheng2020-attn) είναι έως και 20 φορές πιο αργά από τα bmshj2018.

Παρά τον αυστηρό πειραματικό σχεδιασμό, υπάρχουν περιορισμοί που επηρεάζουν τα συμπεράσματα.

- Μέγεθος Δείγματος (Sample Size): Τα πειράματα βασίστηκαν σε ένα περιορισμένο, αν και ομοιόμορφο, σύνολο εικόνων 512×512. Η χρήση ενός μεγαλύτερου και πιο ποικίλου συνόλου εικόνων (π.χ. Kodak) θα βελτιώνει την στατιστική εγκυρότητα των μέσων όρων PSNR/MS-SSIM.
- Υλικό (Hardware): Η ταχύτητα κωδικοποίησης/αποκωδικοποίησης (enc_time, dec_time) εξαρτάται άμεσα από το χρησιμοποιούμενο υλικό (GPU/CPU). Επειδή οι χρόνοι δεν κανονικοποιήθηκαν με βάση συγκεκριμένα flops, αποτελούν σχετική μέτρηση πολυπλοκότητας και όχι απόλυτο μέτρο, απειλώντας την εξωτερική εγκυρότητα των μετρήσεων χρόνου σε διαφορετικές πλατφόρμες.
- Απουσία Video/Motion: Τα πειράματα περιορίστηκαν αυστηρά σε στατικές εικόνες. Η απόδοση των μοντέλων σε συμπίεση video θα εισήγαγε την κρίσιμη παράμετρο του motion estimation (εκτίμηση κίνησης), η οποία δεν αξιολογήθηκε.

Για την περαιτέρω διερεύνηση της επίδοσης των συμπεστών, προτείνονται οι ακόλουθες κατευθύνσεις:

- Ανάλυση Video Compression: Επέκταση της αξιολόγησης σε αλγορίθμους συμπίεσης βίντεο (όπως το Mbt2018-3D ή άλλα μοντέλα κωδικοποίησης κίνησης), χρησιμοποιώντας τις μετρικές bitrate και VMAF για πλήρη κάλυψη του χώρου συμπίεσης.
- Αξιολόγηση Ποιότητας Μηχανής (mAP): Συμπερίληψη μετρικών που βασίζονται στην απόδοση σε downstream tasks (π.χ. Object Detection), όπως το mAP, για να αξιολογηθεί η διατήρηση της πληροφορίας που είναι σημαντική για τις μηχανές.
- Βελτιστοποίηση Ταχύτητας: Διερεύνηση μεθόδων για τη μείωση της υψηλής πολυπλοκότητας των μοντέλων mbt2018 και cheng2020-attn (π.χ. pruning, quantization ή knowledge distillation), ώστε να καταστούν βιώσιμα για εφαρμογές πραγματικού χρόνου χωρίς μεγάλη απώλεια ποιότητας.)

9 Conclusion

Η παρούσα μελέτη αξιολόγησε την επίδοση Ρυθμού-Παραμόρφωσης τριών διαφορετικών αρχιτεκτονικών Μαθημένης Συμπίεσης Εικόνας σε δεδομένα βίντεο. Τα βασικά ευρήματα επιβεβαίωσαν την ιεραρχία επίδοσης των μοντέλων: τα cheng2020-attn και mbt2018 παρουσιάζουν σαφή υπεροχή στην αντικειμενική (PSNR) και αντιληπτική (MS-SSIM) ποιότητα σε σχέση με το απλούστερο bmsjh2018-factorized. Αυτό οφείλεται στην υιοθέτηση πιο σύνθετων μηχανισμών,

όπως το Attention στο cheng2020-attn, που επιτρέπει καλύτερη προσαρμογή στην κατανομή των bits.

Η Μελέτη Αποκοπής (Ablation Study) τόνισε την κρίσιμη σημασία του μηχανισμού Hyperprior, ο οποίος μοντελοποιεί τις εξαρτήσεις των κωδικοποιημένων χαρακτηριστικών. Η προσθήκη του βελτίωσε σημαντικά την επίδοση R-D του μοντέλου bmshj2018, τοποθετώντας το αρκετά πιο πάνω από την Factorized εκδοχή.

Ωστόσο, η μελέτη ανέδειξε τον σημαντικό συμβιβασμό μεταξύ ποιότητας και πολυπλοκότητας: τα μοντέλα υψηλότερης επίδοσης ήταν έως και 20 φορές πιο αργά σε χρόνους κωδικοποίησης/αποκωδικοποίησης (enc_time/dec_time) από το bmshj2018. Αυτό καθιστά τα μοντέλα αυτά μη κατάλληλα για εφαρμογές πραγματικού χρόνου.

Η εργασία, παρότι επιβεβαιώνει την βελτίωση της επίδοσης μέσω της πολυπλοκότητας της αρχιτεκτονικής, παρουσιάζει περιορισμούς:

- Περιορισμένο μέγεθος δείγματος (Sample Size) και ανάλυσης εικόνων (512x512), γεγονός που επηρεάζει τη στατιστική εγκυρότητα των μέσων όρων.
- Οι μετρήσεις χρόνου δεν ήταν κανονικοποιημένες και εξαρτώνται από το υλικό (CPU), αποτελώντας σχετικό και όχι απόλυτο μέτρο πολυπλοκότητας.
- Δεν συμπεριλήφθηκε η κρίσιμη παράμετρος της εκτίμησης κίνησης (motion estimation), καθώς τα πειράματα περιορίστηκαν αυστηρά σε στατικές εικόνες (frame-by-frame image compression).
- Δεν έγινε αξιολόγηση με βάση την ακρίβεια μηχανής (Task Accuracy - mAP) λόγω έλλειψης σχολιασμών αναφοράς στο σύνολο δεδομένων.

Για μελλοντική διερεύνηση, προτείνεται η επέκταση της αξιολόγησης σε αλγορίθμους Video Compression (όπως το Mbt2018-3D), η συμπερίληψη μετρικών ποιότητας μηχανής (mAP) και η διερεύνηση μεθόδων βελτιστοποίησης ταχύτητας (π.χ. pruning, quantization) για να καταστούν τα μοντέλα υψηλής ποιότητας βιώσιμα για εφαρμογές πραγματικού χρόνου.

10 Reference

You should cite ALL the sources from where you drew material. This is done by adding a [?] at the point of the text where you refer to such material.

A list of all citations should be added at the end of the project. Please see how scientific journal articles are written and follow their example.

- [1] Bross, B., Wang, Y. K., Ye, Y., Liu, S., Chen, J., Sullivan, G. J., & Ohm, J. R. (2021). Overview of the versatile video coding (VVC) standard and its applications. *IEEE Transactions on Circuits and Systems for Video Technology*, 31(10), 3736-3764.
- [2] M. Viitanen, J. Sainio, A. Mercat, A. Lemmetti, and J. Vanne, "From HEVC to VVC: the first development steps of a practical intra video encoder," *IEEE Trans. Consumer Electron.*, vol. 68, no. 2, Jan. 2022, pp. 139-148.
- [3] Uvg266, <https://ultravideo.fi/uv266.html>
- [4] Bégaint, J., Racapé, F., Feltman, S., & Pushparaja, A. (2020). Compressai: a pytorch library and evaluation platform for end-to-end compression research. arXiv preprint arXiv:2011.03029.
- [5] CompressAI, <https://interdigitalinc.github.io/CompressAI/intro.html>
- [6] Choi, H., Han, H., Rosewarne, C., & Racapé, F. (2025). CompressAI-Vision: Open-source software to evaluate compression methods for computer vision tasks. arXiv preprint arXiv:2509.20777.
- [7] CompressAI Vision, <https://interdigitalinc.github.io/CompressAI-Vision/>
- [8] <https://r0k.us/graphics/kodak/>
- [9] <https://data.vision.ee.ethz.ch/cv/DIV2K/>
- [10] <https://ultravideo.fi/dataset.html>
- [11]